Trabalho Final - Módulo I Especialização em Inteligência Artificial Aplicada Professores: Dr. Eduardo Noronha, Me. Otávio Calaça, Dr. Eder Brito 13/06/2025



Trabalho Final - Módulo I

Ultimamente, o mercado de criptomoedas tem atraído diversos investidores ao redor do mundo. Neste contexto, você deverá desenvolver um modelo de previsão do preço de fechamento de alguma criptomoeda¹, utilizando uma rede neural multicamadas (MLP - "Multi Layer Perceptron"), ou algum outro modelo abaixo, caso sinta-se confortável.

https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html

https://scikit-learn.org/stable/modules/svm.html#regression

https://scikit-learn.org/stable/modules/sgd.html#regression

https://scikit-learn.org/stable/modules/neighbors.html#nearest-neighbors-regression

https://scikit-learn.org/stable/modules/tree.html#regression

https://scikit-learn.org/stable/modules/ensemble.html#voting-regressor

https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

Para desenvolver este modelo você deverá:

- Utilizar o dataset disponível em: https://www.cryptodatadownload.com, como por exemplo: https://www.cryptodatadownload.com/data/poloniex/
- Crie módulos Python reutilizáveis (exemplo: data_load.py, features.py, models.py, etc.) e inclua docstrings e type hints em todas as funções. Adicione tratamento de erros com o módulo logging.
- 3. Desenvolver as seguintes análises estatísticas nos dados de 10 criptomoedas:
 - a. Obter medidas resumo e medidas de dispersão
 - b. Construir boxplot e/ou histograma do preço de fechamento

¹ BTC, ETH, LTC, XRP, BCH, XMR, DASH, ETC, BAT, ZRX, EOS, LSK, REP. Comportamento de cada criptomoeda pode ser observado em: https://coinmarketcap.com/

Trabalho Final - Módulo I Especialização em Inteligência Artificial Aplicada Professores: Dr. Eduardo Noronha, Me. Otávio Calaça, Dr. Eder Brito 13/06/2025



- Analisar a variabilidade entre as criptomoedas com base nas medidas de dispersão
- d. Construir gráfico de linha com o preço de fechamento destacando a média, mediana e moda ao longo do tempo
- 4. Crie um *script* configurável (main.py) que possa ser executado em linha de comando (CLI) usando **argparse**. Exemplo de parâmetros: --crypto, --model, --kfolds, etc.
- Adicione uma pasta tests/ contendo ao menos três casos de teste automatizados para serem executados usando pytest. Execute os testes automatizados gerando relatórios de cobertura (pytest-cov).
- 6. Pesquisar e escolher variáveis (*features*) de entrada para a sua rede. Você pode usar dados externos (Ex: Relação da moeda com dólar, com real, indicadores macro-econômicos, etc.), ou dados da própria série (média dos últimos 7 dias, desvio padrão dos últimos 7 dias, correlação entre as moedas, etc.). Ou seja, você deverá encontrar as melhores *features* que irá considerar para o seu modelo.
- 7. Aplicar em seu treinamento a estratégia de validação K-fold cross validation.
- 8. Sempre que possível, utilize operações vetorizadas (np.where, np.cumprod, np.roll, etc) em vez de laços explícitos para acelerar cálculos estatísticos.
- 9. Computar o lucro obtido com seu modelo, caso tenha investido U\$ 1,000.00 no primeiro dia de operação, refazendo investimentos de todo o saldo acumulado diariamente, caso a previsão do valor de fechamento do próximo dia seja superior ao do dia atual. Comparar seu modelo MLP com modelo de regressão (linear, e polinomial graus 2 até 10):
 - a. Diagrama de dispersão (com todos modelos)
 - b. Definir os coeficientes de correlação dos regressores
 - c. Determinar a equação que melhor representa os regressores
 - d. Cálculo do erro padrão
 - e. Cálculo do erro padrão entre o MLP e o melhor regressor

Trabalho Final - Módulo I Especialização em Inteligência Artificial Aplicada Professores: Dr. Eduardo Noronha, Me. Otávio Calaça, Dr. Eder Brito 13/06/2025



- f. Plotar um gráfico mostrando a evolução do lucro obtido em cada modelo
- 10. Crie uma função em Python que, com nível de significância de 5%, construa um teste de hipótese analisando se o retorno esperado médio será superior ou igual à x% (a ser definido pelo usuário) baseado na amostra que você utilizou. Realize esta análise para todas as criptomoedas do dataset.
- 11. Realize análises de variância (ANOVA) para comparar os retornos médios diários das criptomoedas.
 - a. Aplique ANOVA para verificar se o retorno médio diário difere entre as criptomoedas analisadas. Caso o resultado seja significativo, realize um teste post hoc para identificar quais moedas diferem entre si.
 - b. Agrupe as criptomoedas com base em alguma característica comum (ex: volatilidade, volume médio negociado, ou retorno médio) e aplique ANOVA para verificar se o retorno médio diário difere entre os grupos formados. Caso o resultado seja significativo, realize um teste post hoc.
- 12. Todos os gráficos devem ser gerados com matplotlib ou seaborn, salvos em figures/ com resolução mínima de 150 dpi. Use subplots quando houver comparações entre modelos.

Boas práticas de código

- Utilize ferramentas de formatação de código e lint (black, ruff, pylint flake8, etc.)
- Inclua requirements.txt e README.md com instruções de execução passo a passo.

Orientações gerais

- Grupos de no **máximo** 3 alunos
- Entrega até o dia 10/Jul/2025
- O código deverá ser disponibilizado e compartilhado no Google Colab (noronha@ifg.edu.br, otavio.xavier@ifg.edu.br e eder.brito@ifg.edu.br)